

## תרגיל בית 4:

מגשים:

אלחנדרו מוסקוסו 332336908

שירז בניטוב 313592958

### שאלה 1.1:

סעיף 1.

$$\Sigma_y = V^T \Sigma_x V$$

$$\begin{aligned} \Sigma_y &= E(yy^T) = E\left((u_i^T x + a_i)(u_i^T x + a_i)^T\right) = E\left[\begin{pmatrix} u_i^T x - u_i^T \mu_x + a_i + u_i^T \mu_x \\ (u_i^T x - u_i^T \mu_x + a_i + u_i^T \mu_x)^T \end{pmatrix}\right] = \\ &= E\left[\begin{pmatrix} u_i^T (x - \mu_x) + a_i + u_i^T \mu_x \\ (u_i^T (x - \mu_x) + a_i + u_i^T \mu_x)^T \end{pmatrix}\right] = \\ &= E\left[\begin{pmatrix} u_i^T (x - \mu_x) + (a_i + u_i^T \mu_x) \\ ((x - \mu_x)^T u_i + (a_i + \mu_x u_i)) \end{pmatrix}\right] = \\ &= E\left[\begin{pmatrix} u_i^T (x - \mu_x)(x - \mu_x)^T u_i + u_i^T (x - \mu_x)(a_i + \mu_x u_i) \\ + (a_i + \mu_x u_i)(x - \mu_x)^T u_i + (a_i + u_i^T \mu_x)(a_i + \mu_x u_i) \end{pmatrix}\right] = \\ &= \begin{bmatrix} u_i^T E\left[(x - \mu_x)(x - \mu_x)^T\right] u_i + E\left[u_i^T (x - \mu_x)(a_i^T + \mu_x u_i)\right] + \\ + E\left[(a_i + \mu_x u_i)(x - \mu_x)^T\right] u_i + (a_i + u_i^T \mu_x)(a_i^T + \mu_x u_i) \end{bmatrix} = \\ &= \begin{bmatrix} u_i^T \Sigma_x u_i + u_i^T \underbrace{E\left[(x - \mu_x)\right]}_{=0} (a_i + \mu_x u_i) + \\ + (a_i + \mu_x u_i) \underbrace{E\left[(x - \mu_x)^T\right]}_{=0} u_i + (a_i + u_i^T \mu_x)(a_i^T + \mu_x u_i) \end{bmatrix} \Big|_{a_i = -u_i^T \mu_x} = \\ &= u_i^T \Sigma_x u_i \\ \Rightarrow V &= \left[ \begin{pmatrix} u_1 \\ \vdots \\ u_D \end{pmatrix}_1, \begin{pmatrix} u_1 \\ \vdots \\ u_D \end{pmatrix}_2, \dots, \begin{pmatrix} u_1 \\ \vdots \\ u_D \end{pmatrix}_d \right] \end{aligned}$$

סעיף 2.

$$a_i = -u_i^T \mu_x \Leftrightarrow$$

$$a_i + u_i^T \mu_x = 0 \Rightarrow$$

$$E[a_i + u_i^T \mu_x] = 0 \Rightarrow$$

$$E[y_i] = 0$$

סעיף 3.

$$\text{Trace}(\Sigma_y) = \sum_{i=1}^d \text{var}(y_i) = \sum_{i=1}^d \lambda_i$$

כלומר סכום הערכים העצמיים שהתקבלו ממטריצת הקווריאנס של  $X$ .

סעיף 4.

אנו מניחים שכל הערכים העצמיים  $\{\lambda_i\}$  של מטריצת הקווריאנס של  $X$  הם שונים כלומר הוקטורים העצמיים אורתוגונליים  $\{u_i\}$  ולכן בלתי תלויים ונוכל לבצע לכסון עבור מטריצת

הקווריאנס  $\Sigma_x$

סעיף 5.

$$u_i = \lambda_i u_i$$

$\Rightarrow$

$$u_i = \lambda_i u_i \Sigma_x^{-1}$$

## שאלה 1.2:

- עבור geometric PCA המטרה הייתה לחפש ייצוג במימד נמוך יותר  $\{y_1, \dots, y_n\} \in R^d$  כך שיתקיים  $x_j = Uy_j + \varepsilon_j$ ,  $j = 1, \dots, n$  ולכן רצינו שההפרש בין הייצוג למקור יהיה מינימלי והשתמשנו ב-MSE כדי לתאר את הבעיה 
$$\min_{U, \{y_j\}} \sum_{j=1}^n \|x_j - Uy_j\|^2, \text{ s.t. } U^T U = I_d$$
 לעומת זאת עבור statistical PCA אנו מחפשים את הכיוון  $u_1$  שעבור הטלה בכיוון שלו נקבל את השונות המקסימלית כלומר  $u_1^T u_1 = 1$ ,  $u_1^* = \arg \max_{u_1} E(u_1^T x)^2$ ,  $s.t.$  עבור statistical PCA לא קיים השימוש ב-MSE מכיוון שבו אנו רוצים למצוא את הכיוון הטוב ביותר להטלה מבחינת שונות, ולא מנסים למצוא קירוב הכי טוב למדידות.

שאלה 2:

סעיף 1.1.

$$k(x, y) = (x^T y)^n = \begin{pmatrix} x_1^n \\ x_2^n \\ \dots \\ x_D^n \end{pmatrix}^T \cdot \begin{pmatrix} y_1^n \\ y_2^n \\ \dots \\ y_D^n \end{pmatrix} = \phi(x)^T \cdot \phi(y)$$

$\Rightarrow$

$$\phi(x) = \begin{pmatrix} x_1^n \\ x_2^n \\ \dots \\ x_D^n \end{pmatrix} = \bar{x}^n$$

$\Rightarrow$

$$R^D \rightarrow R^M$$

when dimension of feature space M is D

סעיף 1.2.

$$\phi(x) = \frac{x^n}{\sqrt{n!}} \exp\left[-\frac{x^2}{2\sigma^2}\right], \quad m = 0, 1, 2, \dots$$

$\Rightarrow$

$$\begin{aligned} k(x, y) &= \langle \phi(x), \phi(y) \rangle = \sum_{n=0}^{\infty} \left( \frac{x^n}{\sqrt{n!}} \exp\left[-\frac{x^2}{2\sigma^2}\right] \right) \left( \frac{y^n}{\sqrt{n!}} \exp\left[-\frac{y^2}{2\sigma^2}\right] \right) = \\ &= \exp\left[-\frac{1}{2\sigma^2} (\|x\|^2 + \|y\|^2)\right] \cdot \sum_{n=0}^{\infty} \frac{(xy)^n}{n!} = \exp\left[-\frac{1}{2\sigma^2} (\|x\|^2 + \|y\|^2)\right] \exp[xy] = \\ &= \exp\left[-\frac{1}{2\sigma^2} (\|x\|^2 - 2\sigma^2 xy + \|y\|^2)\right] = \exp\left[-\frac{1}{2\sigma^2} (\|x\|^2 - 2\sigma^2 x^T y + \|y\|^2)\right] = \\ &= \exp\left[-\frac{1}{2\sigma^2} (\|x - y\|^2)\right] \end{aligned}$$

$\Rightarrow$

$$R^D \rightarrow R^M$$

when dimension of feature space M is  $\infty$

## סעיף 2.

לאחר הוספת מדידה

$$\text{new sample } x^{(N+1)} \in R^D$$

$$\left( \begin{array}{c} \text{when } x^{(N+1)} = \begin{pmatrix} x_1^{(N+1)} \\ x_2^{(N+1)} \\ \dots \\ x_D^{(N+1)} \end{pmatrix} \end{array} \right)$$

נרצה למצוא את הנקודה המתאימה  $y^{(N+1)} \in R^d$ .

- עבור PCA נוכל להשתמש באותה מטריצה  $U^T \in R^{d \times D}$  שנמצאה עבור פתרון הבעיה

$$\min_{U, \{y_j\}} \sum_{j=1}^n \|x_j - Uy_j\|^2, \text{ s.t. } U^T U = I_d$$

ולכן נקבל

$$y^{(N+1)} = U^T_{[d \times D]} \cdot x^{(N+1)}_{[D \times 1]}$$

- עבור KPCA, קודם פתרנו בשימוש ב-

$$y_i = \omega_i^T [\tilde{k}(x_1, x), \tilde{k}(x_2, x), \dots, \tilde{k}(x_N, x)]^T$$

$$\tilde{k}(x, y) = k(x, y) - \frac{1}{N} \sum_{j=1}^N k(x, x_j) - \frac{1}{N} \sum_{i=1}^N k(x_i, x) + \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N k(x_i, x_j)$$

$$\tilde{K} = \Phi^T \Phi = [\tilde{k}_{ij}]$$

when  $\omega_i$  are the eigenvectors of  $\tilde{K}$  -

$$\tilde{K} \omega_i = \lambda_i \omega_i, \quad \|\omega_i\| = \lambda_i^{-1}$$

ולכן כעת בתוספת מדידה,  $y_i = \omega_i^T [\tilde{k}(x_1, x), \tilde{k}(x_2, x), \dots, \tilde{k}(x_N, x), \tilde{k}(x_{N+1}, x)]^T$

כאשר גם כל אחד מהאיברים השתנה עקב ההגדרה של  $\tilde{k}(x, y)$ , אך אם נניח שמדובר ב-  
 $N \gg 1$  כך שתוספת של מדידה אחת לסכומים היא זניחה אז נוכל לומר שאפשר להשתמש  
 בחלק מהחישוב הקודם

$$y_i = \omega_i^T \left[ \boxed{\tilde{k}(x_1, x), \tilde{k}(x_2, x), \dots, \tilde{k}(x_N, x)}_{\substack{\text{from} \\ \text{previous} \\ \text{calculation}}}, \tilde{k}(x_{N+1}, x) \right]^T$$

ובנוגע ל-  $\omega$

$$\tilde{K} \omega_i = \lambda_i \omega_i$$

$$\tilde{K} = [\tilde{k}_{ij}], \quad i, j \in \{1, 2, \dots, N, N+1\}$$

כלומר נצטרך רק להוסיף חישוב עבור המדידה החדשה  $i = N+1$  שנוספה ובכל שאר  
 החישוב שנעשה עבור  $i, j \in \{1, 2, \dots, N\}$  נוכל להשתמש שוב.

### סעיף 3.

עבור KPCA חישבנו את מטריצת הקרנל הממוקצת  $\tilde{K} = \Phi^T \Phi$ . אם נבחר גרעין לינארי כלומר

$$k(x, y) = x^T y = \phi(x)^T \phi(y)$$

$$\phi(x) = x$$

אז הגרעין מתנוון ל-  $\tilde{K} = XX^T$

ולכן בשלב חיפוש הוקטורים העצמיים הבעיה מתנוונת לאותה הבעיה של PCA רגיל (כאשר חיפשנו הטלה בכיוון שתמקסם את השונות).

$$\tilde{K} \omega_i = \lambda_i \omega_i$$

$$\Rightarrow$$

$$P_x u_i = \eta_i u_i$$